

# Aegis

## Un framework per la condivisione sicura di immagini

Marzia De Maina, Chiara Sivieri

Alma Mater Studiorum - Università di Bologna

Gennaio 2026

# Il Problema: la vulnerabilità dei contenuti

## Il Contesto attuale

La diffusione non autorizzata di immagini private (*Revenge Porn*) o documenti sensibili è una minaccia critica. Le piattaforme attuali proteggono i dati **in transito** (HTTPS, E2EE), ma non offrono garanzie sul **contenuto decifrato**.

Il "**Gap Forense**": una volta che l'immagine appare sullo schermo del destinatario, essa esce dal controllo del mittente.

- Uno screenshot o una foto allo schermo bypassano la crittografia.
- Non esiste un legame indissolubile che provi *chi* ha fatto trapelare il file.

## La Soluzione Aegis

Introdurre un livello di **watermarking invisibile** che sopravvive alla ridistribuzione, trasformando l'immagine stessa in una prova forense che identifica mittente e destinatario.

# Scopo e Obiettivi del Progetto

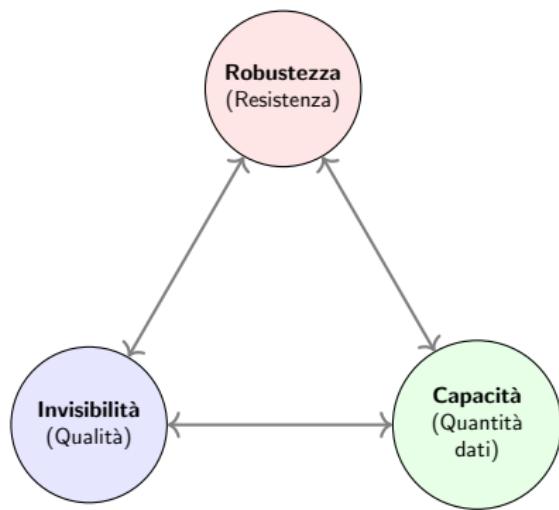
Aegis non vuole impedire la copia (impossibile per definizione), ma garantire la **non ripudiabilità** dell'azione.

- **Invisibilità (Impercepibilità):** il watermark non deve degradare la qualità dell'immagine né destare sospetti nell'osservatore.
- **Robustezza (Resilienza):** la firma deve rimanere leggibile anche dopo compressioni JPEG aggressive, ridimensionamenti, ritagli (cropping) e screenshot.
- **Tracciabilità (Attribution):** il sistema deve estrarre un payload contenente ID Mittente e ID Ricevente in modo univoco.

**Metodologia:** abbiamo implementato e confrontato tre algoritmi distinti (LSB, DCT, Spread Spectrum) per sviluppare una soluzione ibrida ottimale.

# Il Triangolo Impossibile del Watermarking

In letteratura, ogni algoritmo deve bilanciare tre forze contrastanti. Migliorarne una peggiora inevitabilmente le altre.



- **Robustezza:** capacità di resistere agli attacchi (es. compressione).
- **Invisibilità:** assenza di artefatti visivi o rumore.
- **Capacità:** numero di bit inseribili (es. un ID lungo richiede più spazio).

*Aegis sacrifica parzialmente la capacità per massimizzare robustezza e invisibilità.*

# LSB – Least Significant Bit

La tecnica più semplice: sostituzione del bit meno significativo dei pixel con i bit del messaggio.

## Funzionamento

Un pixel RGB (8 bit per canale) ha valori da 0 a 255. Modificare l'ultimo bit cambia il valore di  $\pm 1$ , variazione impercettibile all'occhio umano.

10110101 → 10110100

**Perché lo abbiamo scartato come soluzione principale?** Sebbene offra alta capacità, è estremamente **fragile**.

- Basta una compressione JPEG (che arrotonda i valori dei pixel) per distruggere completamente l'informazione nascosta.
- Utile solo per verifica di integrità (checksum), non per tracciamento robusto.

# DCT – Discrete Cosine Transform

Tecnica che opera nel dominio delle frequenze, simulando il comportamento della compressione JPEG standard.

## Procedura di inserimento:

- ① L'immagine viene divisa in blocchi  $8 \times 8$ .
- ② Si applica la trasformata DCT per separare le basse frequenze (colore medio) dalle alte frequenze (dettagli fini/rumore).
- ③ Il watermark viene inserito sommando un valore ai **coefficienti di media frequenza**.

## Vantaggio Strategico

Le medie frequenze sono percettivamente importanti, quindi gli algoritmi di compressione (come JPEG) tendono a preservarle. Questo rende il watermark **persistente** anche dopo il salvataggio dell'immagine.

# SS – Spread Spectrum

Ispirato alle telecomunicazioni militari anti-interferenza. Il segnale (watermark) viene trattato come se fosse rumore bianco e distribuito sull'intera immagine.

## Modello Matematico:

$$I_w(x, y) = I(x, y) + \alpha \cdot W(x, y)$$

Dove  $W$  è un pattern pseudo-casuale generato da una *chiave segreta*.

- **Sicurezza:** senza la chiave (seed), è matematicamente impossibile distinguere il watermark dal rumore termico del sensore fotografico.
- **Estrazione:** avviene calcolando la correlazione tra l'immagine sospetta e il pattern originale. Se la correlazione supera una soglia, la firma è presente.
- **Limiti:** richiede la chiave originale per la verifica (non-blind).

# Confronto e Scelta Progettuale

Abbiamo analizzato i trade-off per determinare la tecnica migliore per Aegis:

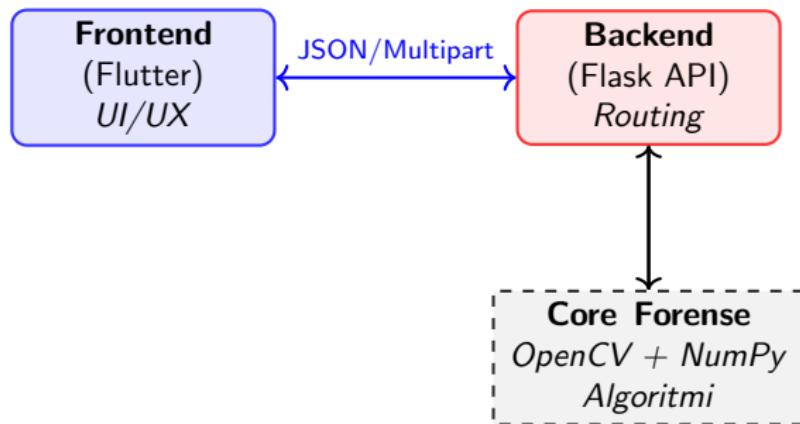
Tecnica	Robustezza	Visibilità	Complessità
LSB	Bassa	Eccellente	Bassa
DCT	Media	Buona	Media
Spread Spectrum	Alta	Eccellente	Alta

## Soluzione Finale: Aegis Combo (Dual Layer)

Per ottenere il massimo da entrambi i mondi, abbiamo implementato un sistema a strati: **DCT** come base robusta + **LSB** come strato superficiale per il controllo integrità.

# Architettura del Sistema

Il sistema implementa un'architettura Client-Server RESTful per separare l'interfaccia utente dalla logica computazionale pesante.



- **Frontend (Dart):** gestisce l'upload sicuro e la visualizzazione dei risultati. Cross-platform (Android, iOS).
- **Backend (Python):** esegue le trasformazioni matriciali (DCT/SVD) necessarie per il watermarking, gestendo le chiavi crittografiche lato server.

# Dettaglio Algoritmo "Aegis Combo"

L'algoritmo implementa una strategia di **doppio embedding** (Dual Layer) per massimizzare le chance di recupero.

① **Stratificazione (Embedding a Cascata):** il sistema applica prima il watermark **DCT** (nel dominio delle frequenze) per garantire la robustezza. Successivamente, sull'immagine risultante, applica il watermark **LSB**.

- *Risultato:* l'immagine contiene due copie della firma a livelli di profondità diversi.

② **Estrazione Adattiva (Fallback Mechanism):** In fase di analisi, l'algoritmo tenta l'approccio più veloce:

- **Step 1:** controlla LSB. Se integro (immagine originale), estrae subito.
- **Step 2:** se LSB è corrotto (compressione/attacco), attiva l'estrazione DCT per recuperare la firma "profonda".

③ **Optimization:** uso del **Canale Verde** per la DCT (miglior rapporto segnale/rumore sui sensori Bayer).

# Risultato Forense e Verifica

Quando un'immagine sospetta viene analizzata, il backend restituisce un oggetto JSON strutturato che funge da evidenza digitale.

```
{  
    "status": "DETECTED",  
    "timestamp": "2026-01-30T10:45:00Z",  
    "evidence": {  
        "technique": "Combo_DCT LSB",  
        "sender_id": "USR_0001",  
        "receiver_id": "USR_0002",  
        "confidence_score": 0.98  
    },  
    "raw_watermark": "USR_0001<->USR_0002###AegisSig"  
}
```

## Analisi del Payload:

- **Evidence:** identifica univocamente chi ha inviato e chi ha ricevuto.
- **Confidence Score:** indica l'affidabilità statistica del rilevamento.
- **Raw Watermark:** la stringa grezza estratta dai bit dell'immagine.

# Testing e Validazione Sperimentale

Il sistema è stato sottoposto a stress test per verificarne i limiti operativi.

## Verifica Funzionale

Test del flusso completo (Handshake):

- Upload immagine mittente.
- Watermarking lato server.
- Download destinatario.
- Re-upload per verifica.

## Stress Test Forense

- **Compressione JPEG (Q=70%):** firma recuperata (grazie al livello DCT).
- **Integrità File:** verifica immediata (grazie al livello LSB).
- **Cropping:** resistenza parziale basata sulla ridondanza dei blocchi DCT.

# Sviluppi Futuri

Aegis è un Proof-of-Concept che pone le basi per una cybersecurity etica e attiva.

## Roadmap verso "Algis"

- **Autenticazione Forte:** implementazione di firme digitali asimmetriche (RSA) per impedire lo spoofing dell'ID utente.
- **AI Detection:** integrazione pre-invio di modelli ML per rilevare deepfake.
- **Web Crawler:** bot automatico per scansionare il web alla ricerca di immagini leakate, utilizzando la firma Aegis come "impronta digitale".

*Conclusione: è possibile bilanciare privacy e tracciabilità in un'unica piattaforma.*

# DEMO

# Grazie per l'attenzione

---

## Q&A